Données pour les TP

Modèles de langage
Master IAAA
Aix Marseille Université

Données pour les TP

- L'apprentissage de modèles de langages nécessite du texte.
- La qualité des modèles est en partie dictée par la quantité de texte sur laquelle ils ont été appris.
- Les modèles actuels sont appris sur des quantités gigantesques de données.
- On n'a pas les moyens d'entraîner de tels modèles.
- Tout petits modèles, appris sur peu de données.
- Trois architectures :
  - Perceptron multicouche (MLP)
  - Réseaux récurrents (RNN)
  - Transformers
- Comparaisons entre modèles entraînés sur la même quantité de données.

Corpus littéraire

Auteur	Nb. d'ouvrages	Nb. de mots
Dumas	5	1 569 291
Flaubert	8	639 534
Hugo	14	1 330 402
Proust	17	1 394 010
Zola	24	3 124 770
Total	68	8 058 007

Table – Répartition des mots par auteur

- Structures syntaxiques correctes et variées
- Vocabulaire riche

Segmentation

Vocab	Long. 1 (%)	Long. 2 (%)	Long. 3+ (%)	Hapax	Taux de frag.
6k	22.04	18.65	59.31	45	1.538
8k	22.50	18.16	59.35	51	1.488
10k	22.86	17.84	59.30	69	1.454
12k	23.14	17.70	59.16	84	1.430

Table – Évaluation des tailles de vocabulaire selon la distribution des longueurs de tokens, le nombre de tokens à une occurrence et le taux de fragmentation.

- Segmentation à l'aide de l'algorithme BPE
- Quatre tailles de vocabulaire : 6k, 8k, 10k et 12k
- La segmentation 12k va constituer notre référence

Segmentation

3*k* le lu #n #di , dix - huit #ième jour du mois d ' a #o #ût 1 #5 #7 #2 , il y avait grande f #ête au l #ouv #re .

4*k* le lu #n #di , dix - huit #ième jour du mois d ' a #oût 1 #5 #7 #2 , il y avait grande fête au louv #re .

5*k* le lu #n #di , dix - huit #ième jour du mois d ' a #oût 1 #5 #7 #2 , il y avait grande fête au louvre .

6*k* le lu #n #di , dix - huit #ième jour du mois d ' a #oût 1 #5 #7 #2 , il y avait grande fête au louvre .

7*k* le lu #ndi , dix - huit #ième jour du mois d ' a #oût 1 #5 #7 #2 , il y avait grande fête au louvre .

8*k* le lu #ndi , dix - huit #ième jour du mois d ' a #oût 1 #5 #7 #2 , il y avait grande fête au louvre .

9*k* le lu #ndi , dix - huit #ième jour du mois d ' a #oût 15 #7 #2 , il y avait grande fête au louvre .

10*k* le lundi , dix - huit #ième jour du mois d ' août 15 #7 #2 , il y avait grande fête au louvre .

12*k* le lundi , dix - huitième jour du mois d ' août 15 #7 #2 , il y avait grande fête au louvre .

Découpage du corpus

- Le corpus est découpé en trois parties :
  - Train : utilisé pour l'apprentissage des modèles (80%).
  - Validation : utilisé pour estimer l'erreur en généralisation lors de l'apprentissage (10%) et déclencher le early stopping.
  - Test : données non utilisées lors de l'apprentissage, utilisé pour calculer l'évaluation des modèles (10%).

Evaluation des modèles

- Perplexité
- Texte à trou

Perplexité

- Etant donné un corpus de Test T et deux modèles M_1 et M_2 attribuant à T les probabilités p_1 et p_2.
- On considère que M_1 est meilleur que M_2 si $p_1 > p_2$.
- On n'utilise pas directement la probabilité, mais la perplexité qui est normalisée par longueur de la séquence :

$$PP(T) = P(T)^{-\frac{1}{|T|}} = \sqrt[|T|]{\frac{1}{P(T)}}$$

- la perplexité évolue comme l'inverse de la probabilité, on recherche le modèle qui minimise la perplexité.
- la probabilité $P(T)$ est généralement décomposée sous la forme d'un produit de probabilités conditionnelles :

$$P(T) = \prod_{i=1}^{|T|} P(w_i | w_1 \dots w_{i-1})$$

Log vraisemblance

- En pratique on utilise souvent le logarithme de la perplexité aussi appelée la log vraisemblance

$$LPP(T) = -\frac{1}{|T|}\sum_{i=1}^{|T|}\log P(w_i|w_1 \dots w_{i-1})$$

Interprétation de la perplexité

- Supposons un vocabulaire composé de trois symboles $\{a, b, c\}$ et un modèle qui produit ces symboles avec la même probabilité $\frac{1}{3}$
- La perplexité d'une séquence de N symboles vaut :

$$\left(\left(\frac{1}{3}\right)^N\right)^{-\frac{1}{N}} = 3$$

- Ce résultat peut s'interpréter de la manière suivante : le modèle de langage hésite entre trois symboles, pour le prochain mot à prédire, avec la même probabilité.
- La perplexité peut être vue comme le facteur de branchement moyen d'un modèle de langage.
- Une perplexité de 1 correspond à un facteur de branchement moyen de 1, le modèle, à tout moment, n'a qu'un choix possible.
- Est-ce une bonne chose ?

Texte à trou

- Les textes à trou constituent une autre manière d'évaluer les modèles.
- Principe : on identifie un mot d'un texte et on essaye de le prédire à l'aide d'un modèle M.
- On détermine le mot le plus probable selon M.
- On note $C_G X C_D$ un texte dans lequel on a enlevé un mot, représenté par X.
- C_G constitue le contexte gauche et C_D le contexte droit.
- On recherche le mot m qui vérifie le critère suivant :

$$\hat{m} = \arg\max_{m \in V} P(C_G, m, C_D)$$

Texte à trou

- Le processus peut être coûteux car V peut être important (dans notre cas 6k, 8k, 10k ou 12k)
- On peut factoriser le calcul de $P(C_G)$ mais pas celui de $P(C_D)$.
- Pour réduire le coût, on a recours à une approximation. Au lieu de calculer arg max sur tout le vocabulaire, on le calcule sur un échantillon du vocabulaire $E(V)$ de taille N.

$$\hat{m} = \underset{m \in E(V)}{\arg\max}\, P(C_G, m, C_D)$$

Texte à trou

- Les N tokens ne sont pas choisis au hasard, on découpe de lexique en 10 plages de fréquences et on choisit 10 tokens dans chaque plage.

Famille	**Plage d'apparitions**		**Nombre de mots**
1	1	80	1 176
2	81	107	1 150
3	108	127	1 214
4	128	153	1 197
5	154	187	1 177
6	188	236	1 166
7	237	317	1 204
8	318	466	1 187
9	467	921	1 187
10	922	845 216	1 186

Table – Répartition du vocabulaire en 10 plages de fréquences.

Metrique

- Pour évaluer la qualité des prédictions dans la tâche de texte à trous, on mesure la capacité du modèle à classer le mot cible (masqué) parmi un ensemble de N candidats.
- Après avoir calculé la vraisemblance (log-probabilité) de chaque candidat en tenant compte des contextes gauche et droit, les candidats sont triés par ordre décroissant.
- Soit $r \in \{1, \ldots, N\}$ le rang obtenu par le mot attendu. On définit le score individuel de la phrase par un rang normalisé :

$$S = \frac{N - r + 1}{N} \tag{1}$$

- Valeurs extrêmes :
  - $S = 1{,}0$: Le mot attendu est prédit en première position ($r = 1$).
  - $S \approx 0{,}0$: Le mot attendu est classé en dernière position ($r = N$).

- La performance globale du modèle est ensuite obtenue en calculant la moyenne arithmétique de ces scores sur l'ensemble des phrases valides.

Les données

- Toutes les données se trouvent dans le fichier `talia_donnees.tgz` qui se trouve à l'adresse suivante : (à télécharger avant le XXX).
- Trois répertoires :
- `bpe_embeddings`
  - `bpe_embeddings_12k_32.txt ... bpe_embeddings_12k_512.txt`
- `corpus`
  - `balises_gru_transformer`
    - `mask_files_100_sentences`
    - `train_12k.bpe`
    - `val_12k.bpe`
    - `test_12k.bpe`
  - `balises_mlp`
- `tokens_candidats_textes_a_trou_12k`
  - `ensemble_1.txt ... ensemble_10.txt`